

Задание 1. Отчет

Введение:

При выполнении задания было проведено исследование близости слов с использованием пакета NLTK и его доступа к базе данных WordNet. Задача заключалась в вычислении близости слов с использованием трех методов: LCH (Leacock-Chodorow Similarity), WUP (Wu-Palmer Similarity) и JCN (Jiang-Conrath Similarity). Затем для каждого метода был получен ранжированный список слов по мере снижения близости, и проведена оценка меры Спирмена для сравнения полученных списков с исходными данными из набора Wordsim 353 Goldstandard.

Шаги и методы:

1. **Загрузка референсных данных** из файлов `wordsim_similarity_goldstandard.txt` , `wordsim_relatedness_goldstandard.txt` , содержащие пары слов и оценки их близости согласно человеческим суждениям.
2. **Вычисление близости слов:** Для каждого метода (LCH, WUP, JCN) были написаны функции для вычисления близости между словами на основе WordNet. Использовались методы `lch_similarity` , `wup_similarity` , `jcn_similarity`
3. **Ранжирование по мере снижения близости:** Для каждого метода был получен ранжированный список пар слов согласно их близости, отсортированный по убыванию.
4. **Оценка меры Спирмена:** Для каждого метода была вычислена мера Спирмена между ранжированным списком слов, полученным с использованием метода, и списком слов из Wordsim 353 Goldstandard. Использовалась функция `spearmanr` из библиотеки `scipy.stats`

Результаты и анализ:

Для файла `wordsim_similarity_goldstandard.txt`

- Мера Спирмена для метода LCH составила 0.6150297875147447
- Мера Спирмена для метода WUP составила 0.6402294680070814
- Мера Спирмена для метода JCN составила 0.23878011030705484

Для файла `wordsim_relatedness_goldstandard.txt`

- Мера Спирмена для метода LCH составила -0.029194113096109125
- Мера Спирмена для метода WUP составила -0.007419451142570079
- Мера Спирмена для метода JCN составила -0.04583089400419602

Можно видеть, что автоматические методы оценки близости слов, такие как LCH, WUP и JCN, демонстрируют недостаточную точность. Они опираются на структуру иерархии семантических отношений в базе данных WordNet и не могут учитывать всю сложность семантики слов в реальном мире.

Тем не менее, они показывают более высокие результаты в оценке близости слов (similarity), чем в оценке их связанности (relatedness). Это может быть связано с тем, что “близость” слов более прямо связана с семантической близостью в иерархии WordNet. В то время как “связанность” слов может включать в себя более широкий спектр отношений, которые сложнее уловить с помощью автоматических методов.

Результаты разнятся и для различных методов: мера Спирмена для метода WUP оказалась выше, чем для метода LCH. В методе LCH учитывается только длина пути, в то время как в методе WUP важную роль играет уровень глубины в иерархии Wordnet, что увеличивает точность результатов применительно к набору Wordsim 353.

JCN использует информационное содержание синсетов, что позволяет учитывать их значение и специфичность, но при этом сильно зависит от качества используемого корпуса для оценки информационного содержания синсетов. При использовании словаря genesis можно наблюдать, что значения, которые получают пары слов либо очень большие, либо очень маленькие, из-за чего получилось меньшее значение меры Спирмена.

Примеры отношений для конкретных пар слов:

1. king - queen

Word to search for:

Display Options:

Key: "S:" = Show Synset (semantic) relations, "W:" = Show Word (lexical) relations
 Display options for sense: (gloss) "an example sentence"

Noun

- [S: \(n\) king](#), [male monarch](#), [Rex](#) (a male sovereign; ruler of a kingdom)
- [S: \(n\) king](#), [queen](#), [world-beater](#) (a competitor who holds a preeminent position)
 - [direct hyponym](#) / [inherited hyponym](#) / [sister term](#)
 - [S: \(n\) rival](#), [challenger](#), [competitor](#), [competition](#), [contender](#) (the contestant you hope to defeat) *"he had respect for his rivals"; "he wanted to know what the competition was doing"*
 - [S: \(n\) champion](#), [champ](#), [title-holder](#) (someone who has won first place in a competition)
 - [S: \(n\) comer](#) (someone with a promising future)
 - [S: \(n\) finalist](#) (a contestant who reaches the final stages of a competition)
 - [S: \(n\) foe](#), [enemy](#) (a personal enemy) *"they had been political foes for years"*
 - [S: \(n\) front-runner](#), [favorite](#), [favourite](#) (a competitor thought likely to win)
 - [S: \(n\) king](#), [queen](#), [world-beater](#) (a competitor who holds a preeminent position)

Методы LCH и WUP дали достаточно большую оценку близости для этих слов. В Wordnet приписывается отношение “sister term”, в то время как человеческая оценка ниже, то есть автоматические методы не учитывают противоположность СМЫСЛОВ.

2. wood - forest

Word to search for:

Display Options:

Key: "S:" = Show Synset (semantic) relations, "W:" = Show Word (lexical) relations
 Display options for sense: (gloss) "an example sentence"

Noun

- [S: \(n\) forest](#), [wood](#), [woods](#) (the trees and other plants in a large densely wooded area)
 - [direct hyponym](#) / [full hyponym](#)
 - [member meronym](#)
 - [direct hyponym](#) / [inherited hyponym](#) / [sister term](#)
 - [S: \(n\) vegetation](#), [flora](#), [botany](#) (all the plant life in a particular region or period) *"Pleistocene vegetation"; "the flora of southern California"; "the botany of China"*
 - [S: \(n\) browse](#) (vegetation (such as young shoots, twigs, and leaves) that is suitable for animals to eat) *"a deer needs to eat twenty pounds of browse every day"*
 - [S: \(n\) brush](#), [brushwood](#), [coppice](#), [copse](#), [thicket](#) (a dense growth of bushes)
 - [S: \(n\) growth](#) (vegetation that has grown) *"a growth of trees"; "the only growth was some salt grass"*
 - [S: \(n\) scrub](#), [chaparral](#), [bush](#) (dense vegetation consisting of stunted trees or bushes)
 - [S: \(n\) stand](#) (a growth of similar plants (usually trees) in a particular area) *"they cut down a stand of trees"*
 - [S: \(n\) forest](#), [wood](#), [woods](#) (the trees and other plants in a large densely wooded area)

Снова относятся как “sister term”, из-за чего автоматические методы выдают высокие оценки близости.

3. **Harvard** - **Yale**

Word to search for:

Display Options:

Key: "S:" = Show Synset (semantic) relations, "W:" = Show Word (lexical) relations
Display options for sense: (gloss) "an example sentence"

Noun

- [S: \(n\) Harvard University](#), **Harvard** (a university in Massachusetts)
 - [member holonym](#)
 - [S: \(n\) Ivy League](#) (a league of universities and colleges in the northeastern United States that have a reputation for scholastic achievement and social prestige)
 - [member meronym](#)
 - [S: \(n\) Brown University](#), [Brown](#) (a university in Rhode Island)
 - [S: \(n\) Columbia University](#), [Columbia](#) (a university in New York City)
 - [S: \(n\) Cornell University](#) (a university in Ithaca, New York)
 - [S: \(n\) Dartmouth College](#), [Dartmouth](#) (a college in New Hampshire)
 - [S: \(n\) Harvard University](#), **Harvard** (a university in Massachusetts)
 - [S: \(n\) Princeton University](#), [Princeton](#) (a university in New Jersey)
 - [S: \(n\) University of Pennsylvania](#), [Pennsylvania](#), [Penn](#) (a university in Philadelphia, Pennsylvania)
 - [S: \(n\) Yale University](#), [Yale](#) (a university in Connecticut)

Оба слова находятся на уровне “member meronym” по отношению к **Ivy League** . При этом метод WUP оценил их ближе, чем метод LCH (LCH: 2.538..., при максимуме 3.637..., WUP: 0.916..., при максимуме 1.0). Здесь можем наблюдать эффект учета уровня глубины в методе WUP.

Выводы:

Автоматические методы оценки близости слов обычно работают на основе структуры иерархии семантических отношений в базе данных WordNet. Однако они не могут учитывать всю сложность и многообразие семантики слов в реальном мире. Вместо этого, они опираются на ограниченное количество факторов, таких как глубина отношений в иерархии, информационное содержание синсетов, из-за чего и возникает неточность в автоматической оценке близости.

Задание выполнила: студентка 219 группы Учар Айгуль