

Задание 2. Отчет

Цель:

Используя предобученную модель, основанную на векторах из файла <https://dl.fbaipublicfiles.com/fasttext/vectors-english/wiki-news-300d-1M.vec.zip> с использованием подхода FastText, вычислить семантическую близость для пар слов из списков wordsim-similarity и wordsim-relatedness. Затем вычислить корреляцию Спирмена между полученными близостями и ручными оценками и сравнить с результатами вычисления близости на основе WordNet.

Шаги и методы:

1. Загрузка предобученных векторов FastText с использованием библиотеки `gensim.models` и метода `KeyedVectors.load_word2vec_format`, который позволяет загружать данные в формате векторов.
2. Загрузка ручных оценок из файлов `wordsim_similarity_goldstandard.txt` и `wordsim_relatedness_goldstandard.txt` при помощи функции `load_goldstandard`.
3. Расчет семантической близости для каждой пары слов из ручных оценок при помощи функции `calc_similarity`. В вызываемой функции `model.similarity(word1, word2)` происходит подсчет близости слов на основе косинусной меры, позволяющей оценить семантическую близость между двумя векторами слов.
4. Вычисление корреляции Спирмена между полученными значениями близости и ручными оценками с использованием функции `spearmanr` из библиотеки `scipy.stats`

Результаты:

Корреляции Спирмена для результатов, полученных на основе Fasttext:

- Для файла `wordsim_similarity_goldstandard.txt` равна 0.8117711534936849
- Для файла `wordsim_relatedness_goldstandard.txt` равна 0.6818611048832751

Корреляции Спирмена для результатов, полученных на основе WordNet:

Для файла `wordsim_similarity_goldstandard.txt`

- Для метода LCH равна 0.6150297875147447
- Для метода WUP равна 0.6402294680070814
- Для метода JCN равна 0.23878011030705484

Для файла `wordsim_relatedness_goldstandard.txt`

- Для метода LCH равна -0.029194113096109125
- Для метода WUP равна -0.007419451142570079
- Для метода JCN равна -0.04583089400419602

Анализ результатов:

Полученные значения меры Спирмена для wordsim-similarity и wordsim-relatedness говорят о том, что существует положительная корреляция между семантической близостью слов, вычисленной при помощи предобученных векторов FastText, и ручными оценками семантической близости слов.

Результаты оценки семантической близости слов (similarity) оказались выше, чем результаты оценки их семантической связанности (relatedness). Это может быть объяснено тем, что при использовании метода FastText на семантическую близость слов значительное влияние оказывает частота встречаемости слов в схожих контекстах. Были получены более низкие результаты для “связанности” слов, так как модель Fasttext может не улавливать сложные отношения и частая встречаемость слов не всегда говорит об их семантической связанности. Например, для пары слов `king` - `cabbage` косинусная мера на основе Fasttext получилась равной 0.38360256 (при минимуме 0.20502558), хотя человеческая оценка равна 0.23 (минимальная). То есть из-за встречаемости этих слов получилась не самая низкая косинусная мера, что не совсем хорошо отражает действительную близость.

Также можно заметить, что метод FastText позволяет получить значения, близкие к человеческим оценкам, в большей степени, чем методы, основанные на WordNet. Методы, обучающиеся на больших корпусах текстов и использующие предобученные готовые векторные представления слов, дают сильное преимущество и лучше улавливают более сложные отношения, в то время как методы WUP, LCH, JCN опираются на ограниченное количество факторов, таких как глубина отношений в иерархии и информационное содержание синсетов.

Метод FastText требует обработки больших объемов данных, в то время как методы, основанные на WordNet могут быть полезны в условиях ограниченности памяти, поскольку они обычно оперируют базой данных, содержащей семантические и лингвистические отношения между словами, без необходимости обрабатывать большие объемы текстовых данных.

Задание выполнила: студентка 219 группы Учар Айгуль