

Задание 5. Отчет

Цель:

Рассмотреть модель <https://demo.deeppavlov.ai/#/ru/ner> для распознавания именованных сущностей (Named Entity Recognition) на пяти русскоязычных текстах, проанализировать результаты работы модели, выявив ошибки и оценив качество работы.

Результаты работы:

1. Текст про вид птиц Хрустан

Хрустан PERSON, или глупая ржанка, или глупая сивка (лат. *Charadrius morinellus*) — вид птиц семейства ржанковых. Гнездится в **Евразии** PLACE_NAME в зоне возвышенной каменистой тундры к востоку от **Норвегии** PLACE_NAME, а также местами в **альпийском** WEATHER_DESCRIPTOR поясе горных районов. Зимует в узкой полосе полупустынь в **Северной Африке** PLACE_NAME и на **Ближнем Востоке** PLACE_NAME от **Марокко** PLACE_NAME до **Ирака** PLACE_NAME. Питается насекомыми и другими беспозвоночными, главным образом жуками, мухами, червями и улитками. По сравнению с другими ржанками менее пуглива и подпускает человека на близкое расстояние, за что среди местного населения получила прозвище «глупая ржанка» или «глупая сивка».

Модель хорошо распознала все географические именованные сущности, и сопоставила классу “weather descriptor” - “альпийском”, что является правильным и при этом достаточно специфичным примером этого класса.

Но при этом модель обозначила слово “Хрустан” примером класса “person”, хотя дальше в тексте объясняется, что это “вид птиц семейства ржанковых”. Также слова “глупая ржанка”, “глупая сивка” никак не выделены.

2. Новость про землетрясение

В **Адыгее** PLACE_NAME зафиксировано землетрясение магнитудой **4,3** CARDINAL, его эпицентр находился в **15 километрах к северо-западу** QUANTITY от **Майкопа.** PLACE_NAME Об этом сообщил **Европейско-Средиземноморский** NORP сейсмологический центр. Согласно публикуемым сведениям, подземные толчки ощущались местными жителями в **01:31** DATETIME (мск). Очаг залегания оценивается специалистами в **10 километров.** QUANTITY Информации о разрушениях и пострадавших нет. Пользователи в сети пишут, что проснулись, когда почувствовали лёгкую вибрацию пола и стен. Отголоски подземных толчков зафиксированы и в районе **Краснодара.** PLACE_NAME

Распознаны все географические названия, численные характеристики и время. При этом слову “Европейско-Средиземноморский” сопоставлена характеристика “NORP” (Nationalities or religious or political groups). Хотя это слово является частью словосочетания “Европейско-Средиземноморский сейсмологический центр”, которую модель должен был обозначить как “название организации”.

3. Новость про многоразовую ракету “Роскосмоса”

Между **двумя** CARDINAL влиятельными личностями в космонавтике заочно состоялся короткий, но при этом очень многозначительный разговор. Недавно на лекции в **Государственном музее истории космонавтики** BUSINESS_NAME имени К. Э. **Циолковского** PERSON в **Калуге** PLACE_NAME глава "**Роскосмоса** BUSINESS_NAME" **Юрий Борисов** PERSON заявил, что разрабатываемая в **России** PLACE_NAME многоразовая ракета "Амур-СПГ" может быть использована до **100** CARDINAL раз. Как раз за **несколько дней** DATETIME до этого в **SpaceX** BUSINESS_NAME отметили рекорд: **первая** ORDINAL ступень **Falcon 9** PRODUCT успешно отработала **20** CARDINAL пусков. Главу **SpaceX** BUSINESS_NAME заинтересовало высказывание **Юрия Борисова.** PERSON **Маск** PERSON прокомментировал его словами: Bring it on, что означает что-то вроде: "**Давайте** WORK_OF_ART", "**Докажите** WORK_OF_ART", "**Покажите** WORK_OF_ART".

Хорошо распознаны все численные характеристики, имена людей, географические названия.

Распознано словосочетание “Государственном музее истории космонавтики” как пример “business name” (Companies, agencies, institutions etc.), правильно распознан класс, но при этом упущено продолжение “имени К. Э. Циолковского”, “К. Э. Циолковского” просто обозначено как “person”.

Пропущено название ракеты “Амур-СПГ”, которое является примером “product”. Хотя ракета SpaceX Falcon 9 распознана и правильно классифицирована.

Также ошибочно выделены слова “Давайте”, “Докажите”, “Покажите” как примеры “Work of art” (Titles of books, songs, paintings etc.)

4. Текст про актрису Эллен Паркер

Эллен Паркер PERSON (англ. Ellen Parker PERSON; род. 30 сентября 1949 DATETIME, Париж PLACE_NAME) — американская NORP актриса. Паркер PERSON выступала во многих театральных постановках и появилась в нескольких кинофильмах, однако, в основном, известна благодаря своей роли Морин Рирдон Бауэр PERSON в дневной мыльной опере «Направляющий свет WORK_OF_ART», где она снималась на регулярной основе с 1986 по 1993 год. DATETIME Ранее роль Морин PERSON играла Эллен Долан. PERSON Её персонаж был неожиданно убит сценаристами в 1993 году DATETIME, а сам момент смерти впоследствии стал считаться одним из самых запоминающихся в истории мыльной оперы.

Хорошо распознаны все имена, даты, географические места, национальность. Приавильно распознано словосочетание “Направляющий свет” как “work of art”.

5. Текст про технологии искусственного интеллекта в Яндекс

С **2009 года** DATETIME компания « **Яндекс** BUSINESS_NAME » развивала свой закрытый проект **Матрикснет** PRODUCT — уникального патентованного алгоритма построения моделей машинного обучения, использующий одну из оригинальных схем градиентного бустинга. И в **июле 2017 года** DATETIME была выложена в открытый доступ библиотека **CatBoost** BUSINESS_NAME, реализующая алгоритм построения моделей машинного обучения, который использует оригинальную схему градиентного бустинга. Технология **CatBoost** PRODUCT используется для улучшения результатов поисковой системы **Яндекс** BUSINESS_NAME, ранжирования персональной ленты рекомендаций — например в **Яндекс.** BUSINESS_NAME **Дзен** PERSON, для расчёта прогноза погоды и в других интернет-сервисах компании « **Яндекс** BUSINESS_NAME »

Выделены все именованные сущности, распознаны даты.

“CatBoost” в первом случае сопоставляется “business name”, а во втором случае “product”, хотя для обоих случаев наиболее подходящий вариант - “product”.

Модель ошибочно отнесла слово “Дзен” к классу “person”, хотя оно является частью слова “Яндекс.Дзен”, которое можно отнести к классу “product”. Ошибка могла возникнуть из-за точки в названии.

Выводы

Модель хорошо справляется с распознаванием именованных сущностей, но при этом возникают ошибки при их классификации. Лучше всего распознаются численные характеристики, даты, имена людей и географические названия. Часто возникают проблемы с названиями организаций, так как модель распознает только часть и упускает полное название, относит словосочетания из названия к разным классам (2 и 3 примеры). Качество работы также зависит от того, насколько часто сущности встречались в корпусах, на которых обучалась модель, от популярности именованных сущностей (например, в 3 примере хорошо распознано более известное название ракеты “Falcon 9”, но не распознано название “Амур-СПГ”. Иногда не очень хорошо оценивается весь контекст (дважды встречающееся слово “CatBoost” в 5 примере относится к разным классам). Также модели сложно учитывать особенности названия организаций и продуктов, например, точка в названии “Яндекс.Дзен” в 5 примере.

Задание выполнила: студентка 219 группы Учар Айгуль