

Отчет по практической работе

Вариант 5. "Сравнение языков"

Условие задачи

Написать программу для сравнения словарного состава параллельных текстов на русском и турецком языках. Программа должна:

1. Составить частотные словари, определить объем уникальных лемм при помощи **collections.Counter** и **set()**.
2. Оценить число уникальных лемм по частям речи и самые частотные слова при помощи библиотеки **pymorphy2** для русского языка и **zeyrek** для турецкого языка.
3. Рассчитать коэффициент лексического богатства, поделив количество элементов в списке лемм на количество элементов в множестве уникальных лемм.
4. Визуализировать результаты при помощи **matplotlib** и **pandas**.

Корректность выполнения программы была проверена на тестах, посчитанных вручную:

1. Файлы test1_rus.txt и test1_tr.txt

Объем частотного словаря для русского текста (уникальные леммы): 12
Объем частотного словаря для турецкого текста (уникальные леммы): 11

Частотный словарь русского текста: [('я', 3), ('бегать', 2), ('в', 2), ('парка', 2), ('часто', 1), ('бег', 1), ('помогать', 1), ('расслабиться', 1), ('когда', 1), ('чувствовать', 1)]

Частотный словарь турецкого текста: [('sık', 2), ('Park', 2), ('koşmak', 2), ('ben', 1), ('rahatlamak', 1), ('yardımcı', 1), ('olmak', 1), ('Koşar', 1), ('kendi', 1), ('özgür', 1)]

Коэффициент лексического богатства для русского текста: 0.70588
Коэффициент лексического богатства для турецкого текста: 0.78571

Уникальные существительные в русском тексте: 2
Уникальные глаголы в русском тексте: 3
Уникальные прилагательные в русском тексте: 1

Уникальные существительные в турецком тексте: 3
Уникальные глаголы в турецком тексте: 4
Уникальные прилагательные в турецком тексте: 3

Все результаты соответствуют ручным подсчетам

2. Файлы test2_rus.txt и test2_tr.txt

Объем частотного словаря для русского текста (уникальные леммы): 11
Объем частотного словаря для турецкого текста (уникальные леммы): 9

Частотный словарь русского текста: [('собака', 3), ('чёрный', 1), ('бегать', 1), ('по', 1), ('двор', 1), ('лаять', 1), ('на', 1), ('прохожий', 1), ('играть', 1), ('с', 1)]
Частотный словарь турецкого текста: [('köpek', 3), ('siyah', 1), ('bahçe', 1), ('koşmak', 1), ('geçmek', 1), ('havlamak', 1), ('top', 1), ('ile', 1), ('oynamak', 1)]

Коэффициент лексического богатства для русского текста: 0.84615
Коэффициент лексического богатства для турецкого текста: 0.81818

Уникальные существительные в русском тексте: 4
Уникальные глаголы в русском тексте: 3
Уникальные прилагательные в русском тексте: 1

Уникальные существительные в турецком тексте: 3
Уникальные глаголы в турецком тексте: 3
Уникальные прилагательные в турецком тексте: 1

Все результаты соответствуют ручным подсчетам

3. Файлы test3_rus.txt и test3_tr.txt

Объем частотного словаря для русского текста (уникальные леммы): 13
Объем частотного словаря для турецкого текста (уникальные леммы): 14

Частотный словарь русского текста: [('улица', 2), ('солнце', 1), ('светить', 1), ('ярко', 1), ('а', 1), ('человек', 1), ('идти', 1), ('по', 1), ('широкий', 1), ('полный', 1)]
Частотный словарь турецкого текста: [('Güneş', 1), ('parlak', 1), ('bir', 1), ('şekil', 1), ('parlamak', 1), ('insan', 1), ('geniş', 1), ('cadde', 1), ('yürümek', 1), ('Cad', 1)]

Коэффициент лексического богатства для русского текста: 0.92857
Коэффициент лексического богатства для турецкого текста: 1.00000

Уникальные существительные в русском тексте: 5
Уникальные глаголы в русском тексте: 2
Уникальные прилагательные в русском тексте: 1

Уникальные существительные в турецком тексте: 6
Уникальные глаголы в турецком тексте: 2
Уникальные прилагательные в турецком тексте: 4

Все результаты соответствуют ручным подсчетам

Для сравнения было взято произведение **"Преступление и наказание"** Федора Достоевского на русском и турецком языках.

Перевод выполнен для министерства образования Республики Турция переводчиком Хасаном Али Эдизом.

Были выявлены следующие особенности текстов произведения для каждого языка:

1. Лексическое богатство

Результаты программы:

Коэффициент лексического богатства для русского текста: 0.07365

Коэффициент лексического богатства для турецкого текста: 0.03308

Коэффициент для русского языка получился больше, чем для турецкого. Русский текст может демонстрировать более высокие значения за счет более разнообразного лексикона, тогда как турецкий текст может быть проще по структуре, так как используется перевод текста с русского оригинала, в переводе содержатся более универсальные варианты слов.

2. Части речи**Результаты программы для русского языка:**

Уникальные существительные в русском тексте: 4669

Уникальные глаголы в русском тексте: 3447

Уникальные прилагательные в русском тексте: 1963

Результаты программы для турецкого языка:

Уникальные существительные в турецком тексте: 3562

Уникальные глаголы в турецком тексте: 1752

Уникальные прилагательные в турецком тексте: 2035

Уникальных существительных и глаголов в русском языке получилось больше, прилагательных же больше в турецком языке. Русский язык имеет богатую систему словообразования, особенно для существительных и глаголов. Существительные могут образовываться с помощью различных приставок и суффиксов, глаголы также могут иметь множество форм (совершенный/несовершенный вид, наклонение, время и т. д.). Преобладание количества прилагательных в турецком языке возможно связано с процессом перевода и адаптацией под особенности языка:

- Часто причастные в русском языке переводятся в тексте в турецком языке на прилагательные. Примеры:

Русский язык: «Не то чтоб он был так труслив и забит, совсем даже напротив...»

Турецкий язык: «Korkak ve çekingen biri değildi aslında»
Перевод для слова «забит» (краткое причастие) - «çekingen»
(прилагательное)

Русский язык: «Небольшая комната ... была в эту минуту ярко
освещена заходящим солнцем.»

Турецкий язык: «Batmakta olan güneşin ışıklarıyla apaydınlıktı
oda»

Перевод для слова «освещена» (причастие) - «apaydınlıktı»
(прилагательное)

- Часто создаются более детализированные описания, что помогает турецкому читателю лучше понимать текст иностранного автора с русскими культурными особенностями.

Русский язык: «Он был в поддевке и в страшно засаленном черном атласном жилете, без галстука, а все лицо его было как будто смазано маслом, точно железный замок»

Турецкий язык: «Sırtında bir kaban ve yağdan ıslıl ıslıl olmuş kara atlastan bir yelek vardı, kravatsızdı, suratı bir demir kilit gibi sanki yağa bulanmıştı.»

В турецком языке не существует прямого перевода слова «засаленном», в переводе 1 слово заменяется на 4 слова «yağdan ıslıl ıslıl olmuş» (существительное, прилагательное, прилагательное, глагол)

3. Уникальные леммы

Результат программы:

Объем частотного словаря для русского текста (уникальные леммы):
12919

Объем частотного словаря для турецкого текста (уникальные леммы): 5317


Низкий результат для турецкого языка связан с работой библиотеки zeugrek, много слов не было опознано, все такие слова были добавлены в массив лемм как “UNK” (от “unknown”)

4. Частотные слова


Порядок частотных слов отличается для каждого языка, что связано с особенностями языков. Например, слово “И” является самым

частым в тексте на русском языке, в тексте на турецком языке эквивалент со значением “И” - “ve” является самым частым четвертым словом. В турецком языке самыми частыми получились леммы “bir” (“один”) и “bu” (“этот”), так как часто используются в речи как вспомогательное слово.


Top 10 Frequent Words in Russian Text






Top 10 Frequent Words in Turkish Text



Диаграммы для прилагательных, глаголов, существительных в тексте на русском языке:



Диаграммы для прилагательных, глаголов, существительных в тексте на турецком языке:





При сравнении одинаковых частей речи для русского и турецкого языка наблюдается соответствие русских слов и их аналогов на турецком языке с небольшими смещениями. В турецком языке чаще встречаются вспомогательные слова (слова со значением “этот”, “вещь” и т. д.), так как видимо переводчику пришлось их использовать больше, чтобы адаптировать текст под турецкий язык. Пример:

Русский язык: «Что-то совершалось в нем как бы новое, и вместе с тем ощутилась какая-то жажда людей.»

Турецкий язык: «Ama şu anda birdenbire bir şey onu insanlara doğru itmeye başlamıştı.» (1 слово «что-то» переводится двумя словами «bir şey»)

5. Сравнение по частям речи



В русском языке чаще всего встречаются по порядку: существительные, глаголы, союзы, местоимения, наречия, предлоги, прилагательные

В турецком языке: существительные, глаголы, прилагательные, наречия, союзы.

Можно видеть, что диаграмма для русского языка содержит большее количество частей речи, что может быть связано с качеством обработки анализаторов для русского языка и турецкого, а также с тем, что в русском языке больше частей речи.

Заключение

В ходе работы был проведен сравнительный анализ параллельных текстов на русском и турецком языках на основе произведения «Преступление и наказание». Русский текст показал более высокое лексическое богатство и большее количество уникальных существительных и глаголов, что связано с богатой системой словообразования и разнообразием форм в оригинале произведения. Одно сложное слово в русском языке могло быть заменено несколькими простыми словами в турецком языке. Турецкий текст содержал больше прилагательных, что может объясняться заменой причастных в русском языке на прилагательные в турецком переводе и адаптацией перевода под особенности языка. Частотные словари также продемонстрировали различия: в русском языке чаще встречались союзы и местоимения, в то время как в турецком — вспомогательные слова, что связано с особенностями перевода. Разница в количестве уникальных лемм указывает на влияние морфологических анализаторов и языковые различия.

Практическое задание:

Создаются частотные словари для текстов на русском и турецком языках и сохранения этих словарей в текстовые файлы. Код включает функции для подсчета частоты слов и записи результатов в удобном формате.

Программу можно использовать в лингвистических исследованиях, анализе текстов или при разработке систем обработки естественного языка, где необходимо оценить распределение слов в текстах.

Код приложен в дополнительном файле `application.py`, где основная программа является модулем. Программа создает словари и сохраняет их в 2 отдельных файла: `frequency_russian.txt` и `frequency_turkish.txt`